

Forecasting probabilistico con modelli di diffusione — sintesi di una pagina

Esame: Probabilistic Machine Learning — Università di Trieste, Prof. Luca Bortolussi. Gruppo: Giovanni Mason (SM3800158), Lorenzo Di Bernardo (SM3800132), Lorenzo Karol Gobbo (SM28A00018). Repo: github.com/Icaica14/pml-diffusion-tsf

Domanda

Volevamo capire se un modello di diffusione, usato per fare forecasting probabilistico (stimare una distribuzione del futuro, non un solo numero), dia previsioni più accurate o meglio calibrate rispetto a baseline classiche e deep, e a quale costo di calcolo. Abbiamo formulato tutto come stima di $p(\text{futuro} \mid \text{passato})$.

Dati

Due dataset, stessa pipeline (cambia solo il file di configurazione):

- Exchange (8 serie, tassi di cambio): lo usiamo come controllo. È vicino a un random walk, quindi ci aspettiamo che i modelli complessi non aiutino; serve a verificare che la pipeline non stia “barando”.
- Electricity (321 serie orarie): è il dataset su cui ragioniamo davvero, con forte stagionalità giornaliera e settimanale. Contesto $H=168$ ore, orizzonte $=24$ ore, 100 campioni per stimare la distribuzione, seed 42.

Abbiamo usato il file grezzo LSTNet con un nostro split 70/10/20, non lo split del benchmark `electricity_nips`. Di conseguenza i nostri CRPS sono un confronto interno tra i nostri modelli, non un confronto diretto con i numeri pubblicati nei paper.

Modelli (scala a complessità crescente)

- M0 seasonal-naive — il futuro ripete il ciclo stagionale; nessun addestramento.
- M1 ARIMA — un modello lineare per ciascuna serie.
- M2 DeepAR — rete ricorrente probabilistica, addestrata su tutte le serie insieme.
- M3 TimeGrad — diffusione condizionata, autoregressiva (genera un passo alla volta).
- M4 TimeDiff — diffusione non-autoregressiva (denoisa l'intero blocco futuro in una volta), più una variante M4 ϵ che predice il rumore invece del segnale (ablazione).

Metriche

MASE (accuratezza puntuale, $1 \approx$ seasonal-naive), CRPS (qualità dell'intera distribuzione predittiva), copertura e ampiezza degli intervalli al 50% e 90% (calibrazione), e i tempi di fit e di campionamento.

Tre risultati

1. Su Electricity, nel nostro setting, nessun modello addestrato batte il seasonal-naive sul CRPS (160.5): DeepAR 253.7, TimeGrad 241.6, TimeDiff 287.3, ARIMA 867.5. Con questo protocollo e questo budget, la baseline stagionale è difficile da superare.
2. Il modello meglio calibrato è DeepAR, non una diffusione. TimeGrad batte DeepAR sul CRPS ma resta sopra il naive e costa molto in campionamento (circa 4 ore).

3. Con TimeDiff la parametrizzazione cambia molto il risultato: in forma x_0 la distribuzione predittiva collassa (copertura ≈ 0 , e il CRPS coincide quasi con la MAE); la variante ε non risolve il problema ma lo ribalta nell'eccesso opposto (copertura ≈ 1). Una spiegazione plausibile è che sul blocco non-autoregressivo né x_0 né ε “nudi” producano una varianza ben calibrata.

Limiti dichiarati

Un solo seed; budget di calcolo modesto (50 epoche, 100 step di diffusione, poco tuning); lo split è nostro e non quello del benchmark; la parte sul valore economico (E6) è solo una demo su M0. Gli esperimenti E0 (split ufficiale), E2 (orizzonte), E3 (numero di step) ed E4 (regime-shift) sono predisposti o in corso, non risultati finali.

Cosa mandiamo al professore

Le slide in PDF, il report (`REPORT.md`, oppure `REPORT.pdf`), il link al repository GitHub e questa sintesi.