

Forecasting probabilistico con modelli di diffusione

Un confronto controllato su consumi elettrici · M0 → M4

Giovanni Mason (SM3800158) · Lorenzo Di Bernardo
(SM3800132) · Lorenzo Karol Gobbo (SM28A00018) —
PML, Prof. Bortolussi, UniTS

Giugno 2026

La domanda

- ▶ Forecasting probabilistico: prevediamo una distribuzione del futuro, non un singolo numero.
- ▶ Una scala di 5 modelli a complessità crescente: M0 seasonal-naive → M1 ARIMA → M2 DeepAR → M3 TimeGrad → M4 TimeDiff.
- ▶ Domanda guida: un modello di diffusione produce incertezza migliore — e a che costo?

Perché forecasting probabilistico

- ▶ Prevediamo $p(\text{futuro} \mid \text{passato}) = p(x_{\{t+1:t+\tau\}} \mid x_{\{t-H+1:t\}})$.
- ▶ Una previsione puntuale nasconde il rischio; una distribuzione lo quantifica.
- ▶ Servono intervalli calibrati: se dico “90%”, devono coprire davvero ~90%.
- ▶ Le decisioni sotto incertezza (riserva di rete, sbilanciamento, prezzo) usano i quantili, non solo la media.
- ▶ H = contesto (passato osservato) · τ = orizzonte (futuro previsto).

Dataset e protocollo

- ▶ Electricity: $D = 321$ serie orarie di consumo, forte stagionalità giornaliera e settimanale.
- ▶ Split 70/10/20 (train/val/test) · contesto $H = 168$ ore (1 settimana) · orizzonte $\tau = 24$ ore.
- ▶ $S = 100$ campioni per la distribuzione predittiva · seed = 42.
- ▶ Caveat di onestà (E0): file grezzo LSTNet col nostro split, non electricity_nips → i nostri CRPS non sono direttamente confrontabili coi numeri pubblicati. È un confronto interno, controllato.

Da Exchange a Electricity — perché due dataset

- ▶ Exchange ($D = 8$, giornaliero, quasi random walk): sandbox per validare la pipeline. Qui i modelli deep non battono la persistenza — ed è atteso: controllo negativo.
- ▶ Electricity ($D = 321$, orario, stagionale): il test rilevante, struttura ricca, rilevanza industriale.
- ▶ Messaggio: cambia il regime del segnale, cambia chi vince.
- ▶ Nota: MASE e CRPS non sono confrontabili tra i due dataset (scale e denominatori diversi).

La scala dei modelli: M0 → M4

- ▶ M0 — seasonal-naive: “domani come il ciclo precedente”. Zero training, fortissimo sulle serie stagionali.
- ▶ M1 — ARIMA: lineare classico, un modello per canale (321 modelli).
- ▶ M2 — DeepAR: RNN autoregressiva probabilistica, addestrata su tutte le serie insieme.
- ▶ M3 — TimeGrad: diffusione autoregressiva condizionata — genera il futuro un passo alla volta.
- ▶ M4 — TimeDiff: diffusione non-autoregressiva — denoisa l'intero blocco futuro in una catena → sampling molto più rapido. Point forecast nitido, ma incertezza collassata.
- ▶ Asse: più espressività → (forse) incertezza migliore → più costo. E M4 mostra che il design (AR vs non-AR) sposta il costo, non solo la scala.

TimeGrad, in modo intuitivo

- ▶ Forward: parto dal dato vero e aggiungo rumore gaussiano, un po' alla volta, finché diventa rumore puro.
- ▶ Reverse: addestro una rete a invertire quei passi; a generazione, parto da rumore e lo ripulisco.
- ▶ Per il forecasting: la ripulitura è condizionata sul passato (stato di un RNN che riassume H ore); ripeto il sampling S volte → S traiettorie future = la distribuzione predittiva.
- ▶ Il prezzo: ogni campione richiede molti passi di denoising → sampling lento (diff_steps = 100, predict $\approx$ 4h 19min su L4).

Come misuriamo

- ▶ Accuratezza puntuale: MAE, RMSE, MASE (1 = come il seasonal-naive; < 1 = meglio del baseline).
- ▶ Qualità probabilistica: CRPS e pinball loss — premiano una distribuzione intera ben piazzata. Più basso = meglio.
- ▶ Calibrazione: cov50 $\rightarrow$ 0.50 e cov90 $\rightarrow$ 0.90 (le bande coprono quel che promettono?); width = sharpness.
- ▶ Costo: fit_s (training) e predict_s (sampling).
- ▶ Un modello utile deve avere MASE < 1 e CRPS basso a un costo accettabile.


Risultati su Electricity

- ▶ Barra da battere: CRPS = 160.5 (M0) — nessun deep la supera (DeepAR 253.7; TimeGrad 241.6, il più vicino; TimeDiff 287.3).
- ▶ M4 — doppio volto: MAE più bassa dei deep al costo minimo (~41 min vs ~4h19 di M3), ma cov 0.003 / 0.008 → distribuzione degenerare (CRPS $\approx$ MAE; dettaglio in B7).

Modello	MASE	CRPS	cov50	cov90
M0 seasonal-naive	1.00	160.5	0.497	0.885
M1 ARIMA	3.66	867.5	0.592	0.930
M2 DeepAR	1.83	253.7	0.466	0.831
M3 TimeGrad	1.39	241.6	0.279	0.647
M4 TimeDiff	1.40	287.3	0.003	0.008


Risultati — CRPS a confronto

- Barre = CRPS per modello (↓ meglio). La soglia di $M0 = 160.5$ è la riga che nessun deep supera: TimeGrad le si avvicina, TimeDiff (incertezza collassata) è il più alto.



Qualità vs costo — il vero trade-off

- ▶ Scatter CRPS (qualità, ↓) vs predict_s (costo, ↓); angolo basso-sinistra = ideale.
- ▶ M0 è economico e buono (sorpresa). M2 paga di più per una qualità peggiore di M0.
- ▶ M3 è il più costoso (~4h19) e arriva solo a 241.6: il costo non è ripagato.
- ▶ M4 è il punto più a sinistra (il più economico dei deep) ma CRPS 287, il più alto: il non-AR compra velocità, non calibrazione.
- ▶ Non basta vincere sul CRPS: bisogna vincere abbastanza da giustificare il costo — e la velocità non vale se l'incertezza è rotta.




Conclusioni e limiti

- ▶ Take-home: non “diffusion vince”, ma il trade-off espressività $\leftrightarrow$ calibrazione $\leftrightarrow$ costo. Su un segnale molto stagionale un baseline semplice è una soglia seria.
- ▶ M3: migliora DeepAR (253.7 $\rightarrow$ 241.6) ma non il seasonal-naive (160.5). Valore metodologico, non una vittoria.
- ▶ M4 — il design conta: $\sim 6\times$ più rapido di M3, MAE più bassa tra i deep, ma in x_0 -prediction la distribuzione collassa ($\text{cov} \approx 0$). L’ablazione ε (M4 ε) lo conferma per assurdo: predire il rumore non ricalibra, ribalta nell’estremo opposto ($\text{cov} \approx 1$, bande enormi, MASE 4.0). $\rightarrow x_0$ ed ε sono i due estremi; la calibrazione vera non è uno switch di parametrizzazione.
- ▶ Limiti: split non-benchmark (E0); ARIMA per-canale; sampling costoso (M3); un solo seed; no tuning esteso.
- ▶ Lavori futuri: calibrare oltre x_0/ε (σ_θ appresa, conformal); split electricity_nips; CSDI; DDIM; più seed.

Backup B1a — Copertura empirica (calibrazione)

- ▶ Copertura osservata vs nominale: $\text{cov}50 \rightarrow 0.50$, $\text{cov}90 \rightarrow 0.90$. Sotto la diagonale = troppo sicuro; sopra = troppo incerto.
- ▶ M4 (x0) schiacciato sul pavimento ($\text{cov} \approx 0$); M4 ϵ sul soffitto ($\text{cov} \approx 1$); DeepAR il più vicino alla diagonale.
- ▶ Uso: “come fai a dire che un modello è ben calibrato?”


calibrazione — sotto la diagonale = troppo sicuro · sopra = troppo i



Backup B1b — Sharpness (ampiezza delle bande)


- ▶ $\text{width50}/\text{width90}$ = quanto sono larghe le bande. Va letta insieme alla copertura: stretta + copertura = falsa sicurezza; larga + copertura = incertezza onesta.
- ▶ M4 (x0) bande ≈ 0 (false-sicuro); M4ε bande enormi ($\sim 7\,700 / 11\,400$, le più larghe della scala).
- ▶ Uso: “una banda stretta è sempre meglio?” → no, conta solo accanto alla copertura.

Calibrazione = copertura E ampiezza insieme



Backup B7 — I due volti della parametrizzazione (x_0 vs ε)

- ▶ Non-AR: denoisa l'intero blocco $\tau \times D$ in una catena $\rightarrow$ da qui la velocità.
- ▶ x_0 collassa: cov 0.003/0.008, width ≈ 0 , CRPS $\approx$ MAE = massa puntiforme. Perché: la rete predice un x_0 quasi costante (contesto + x_{ar}), ignora il rumore x_t ; varianza residua $1 - \bar{\alpha}_0 \approx 6 \cdot 10^{-4} \rightarrow$ std ≈ 0 (future-mixup aggrava).
- ▶ La presunta cura, ε , ribalta: M4 ε sovra-disperde — cov50 0.998, cov90 1.000, width50 7 686, width90 11 359 (le più larghe della scala), MASE 4.02.
- ▶ Lezione: x_0 ed ε = due estremi (sotto/sovra-confidente); x_0 è il male minore (scelta del paper TimeDiff); la calibrazione vera richiede di più (σ_θ appresa, o conformal).
- ▶ Bonus: il meglio calibrato della scala è DeepAR, non una diffusione.



Altre slide di backup (testo, per il Q&A)

- ▶ B2 — Tabella completa:
results/tables/comparison_electricity.md (tutte le colonne, vincitore per colonna in grassetto).
- ▶ B3 — Perché ARIMA va male: auto-ARIMA per-canale su 321 serie, ordini eterogenei, fragilità, costo.
- ▶ B4 — Math della diffusione: $q(x_t|x_0)$, predizione del rumore ε , loss semplificata; toy DDPM 1-D.
- ▶ B5 — Exchange, risultati:
results/tables/comparison_exchange.md (controllo negativo: deep < naive).
- ▶ B6 — DeepAR senza time-features: effetto delle covariate calendario (se la riga deepar_notf è in registry).